




FIAP

RELATÓRIO TÉCNICO



Alexandre Natã Vicente
Antônio Cláudio Almeida
Cyd Ferreira Rodrigues
David Catherink
Marcelo Macedo Klotz

FIAP - Postech em IA para Devs



1 Sumário

1	Sumário	2
2	Sobre o relatório.....	3
3	Grupo de trabalho	4
4	Introdução.....	5
5	Links relacionados.....	6
6	Contexto e objetivos	7
6.1	Contexto.....	7
6.2	Objetivos	7
7	Metodologia	9
8	Resultados e Avaliação.....	10
9	Discussão e Governança.....	11
10	Conclusão	12

2 Sobre o relatório

Este relatório integra a **Terceira Fase** do Tech Challenge da Pós-Tech em IA para Desenvolvedores da FIAP, pela qual o grupo desenvolveu um protótipo de assistente virtual voltado para a saúde da mulher, com foco específico em triagem ginecológica e apoio à decisão clínica.

O processo foi estruturado para aplicar os conceitos fundamentais da Fase 3 do curso, integrando ajuste fino de modelos, recuperação de informações e orquestração de fluxos complexos, conforme instruções fornecidas pela FIAP.

3 Grupo de trabalho

O grupo responsável por este desafio foi composto pelos seguintes integrantes da **Secretaria de Segurança Pública do Distrito Federal (SSP/DF)**:

- Alexandre Natã Vicente (**rm370024**) (ale.n.vicente@gmail.com)
- Antônio Cláudio Almeida (**rm370052**) (antonioalmeida@gmail.com)
- Cyd Ferreira Rodrigues (**rm370004**) (cydnelson@gmail.com)
- David Catherinck (**rm369997**) (d.catherinck@gmail.com)
- Marcelo Macedo Klotz (**rm370010**) (marceloklotz@gmail.com)

4 Introdução

O projeto seguiu uma metodologia dividida em etapas técnicas claras:

- **Preparação do Ambiente:** Configuração do Google Colab com a instalação de bibliotecas essenciais como LangChain, LangGraph, Transformers e FAISS.
- **Criação de Dados Sintéticos:** Construção de um dataset especializado (health_qa.jsonl) contendo cerca de 100 exemplos de perguntas e respostas sobre temas como gestação, menopausa e violência doméstica para fundamentar o treinamento.
- **Ajuste Fino (Fine-tuning) com LoRA:** Utilização da técnica Low-Rank Adaptation (LoRA) para treinar o modelo base sshleifer/tiny-gpt2. Embora o modelo escolhido seja pequeno para permitir a execução em CPU, ele serviu como prova de conceito para o pipeline de treinamento.
- **Implementação de RAG (Retrieval-Augmented Generation):** Integração do modelo a uma base de conhecimento de protocolos clínicos usando a biblioteca FAISS para busca vetorial. Isso permite que o assistente recupere informações precisas de documentos antes de gerar uma resposta.
- **Orquestração com LangGraph:** Criação de um grafo de estados para gerenciar o fluxo de triagem. O sistema coleta sinais de alerta, avalia o nível de risco (Alto ou Baixo) e decide a conduta médica apropriada (encaminhamento urgente ou orientação de rotina).
- **Avaliação e Testes:** Execução de uma bateria de testes automatizados com cenários clínicos reais para validar a lógica de decisão e a acurácia da classificação de risco.

5 Links relacionados

Os arquivos relacionados a este desafio podem ser acessados por meio dos seguintes endereços eletrônicos:

- **Github da Terceira Fase:**

<https://github.com/marceloklotz/fiap-terceira-fase/tree/main>

- **Notebook:**

https://github.com/marceloklotz/fiap-terceira-fase/blob/main/FIAP_Fase_3.ipynb

- **Vídeo explicativo:**

<https://youtu.be/4wX8KlxYdJ4>



6 Contexto e objetivos

6.1 Contexto

Este projeto foi desenvolvido como parte integrante da Fase 3 da Pós-Tech em IA para Devs (FIAP), cujo foco principal é o domínio de ferramentas avançadas da OpenAI, orquestração de agentes e personalização de modelos de linguagem. O trabalho propõe a criação de um protótipo de assistente virtual aplicado à saúde da mulher, concentrando-se especificamente na triagem ginecológica e no apoio à decisão clínica.

A solução surge em um cenário onde a inteligência artificial busca atuar como uma camada adicional de proteção e eficiência nos serviços de saúde, auxiliando na detecção precoce de situações de risco e na padronização de respostas mínimas, sem jamais substituir o julgamento soberano do profissional médico.

6.2 Objetivos

O objetivo central deste trabalho é demonstrar a viabilidade técnica e a integração coerente de três pilares tecnológicos fundamentais aprendidos durante a fase:

- **Ajuste Fino Eficiente (Fine-tuning com LoRA):** Realizar a especialização de um modelo de linguagem pré-treinado no domínio da saúde feminina, utilizando a técnica de *Low-Rank Adaptation* para viabilizar o treinamento em ambientes de recursos computacionais limitados (CPU).
- **Geração Aumentada por Recuperação (RAG):** Integrar o modelo a uma base de conhecimento estruturada, composta por protocolos clínicos simplificados, para garantir que as respostas da IA sejam fundamentadas em diretrizes médicas reais e ofereçam transparência sobre as fontes utilizadas.
- **Orquestração de Fluxos Complexos (LangGraph):** Implementar um grafo de estados para gerenciar o processo de triagem, permitindo a separação clara entre regras de decisão determinísticas (essenciais para segurança em casos de alto risco) e a geração de texto probabilística da IA.

Objetivos Específicos de Negócio e Segurança:

- Simular um sistema capaz de **identificar sinais de alerta** e classificar automaticamente o nível de risco (alto ou baixo) em cenários simulados.
- Garantir a **segurança do paciente**, assegurando que casos críticos (como suspeita de pré-eclâmpsia ou violência doméstica) acionem condutas imediatas de encaminhamento sem depender da "criatividade" do modelo de linguagem.
- Promover a **governança clínica**, criando um sistema auditável e transparente que reforce que a ferramenta é um suporte à decisão e não um substituto da avaliação presencial.

7 Metodologia

A implementação foi dividida em etapas técnicas progressivas executadas em ambiente Google Colab:

- **Etapas 1 - Preparação do Ambiente:** Instalação de bibliotecas essenciais como *LangChain*, *LangGraph*, *Transformers* e *FAISS*.
- **Etapas 2 - Geração de Dados:** Criação de um dataset sintético (*health_qa.jsonl*) com aproximadamente **100 exemplos** de instruções médicas sobre temas como gestação, puerpério e violência doméstica.
- **Etapas 3 - Fine-tuning com LoRA:** O modelo base *sshleifer/tiny-gpt2* foi ajustado utilizando a técnica *Low-Rank Adaptation*. Apenas **64 parâmetros (0,03%)** foram treinados, permitindo a execução em CPU.
- **Etapas 4 - Implementação de RAG:** Construção de uma base de conhecimento com protocolos clínicos simplificados. Utilizou-se o modelo *all-MiniLM-L6-v2* para embeddings e a biblioteca **FAISS** para busca vetorial, garantindo que o assistente recupere fontes antes de responder.
- **Etapas 5 - Orquestração com LangGraph:** Desenvolvimento de um grafo de estados para gerenciar a triagem. O fluxo inclui nodos para **coleta de sinais**, **avaliação de risco** e definição de **conduta** (urgente ou rotina).

8 Resultados e Avaliação

O protótipo foi submetido a uma bateria de testes sistemática com cenários clínicos simulados. Os principais resultados obtidos foram:

- **Acurácia Lógica:** O sistema apresentou **100% de acerto** na classificação de risco e na escolha da conduta para os casos testados, como suspeita de pré-eclâmpsia e violência doméstica.
- **Desempenho do Modelo:** O processo de fine-tuning estabilizou a perda (*loss*) em cerca de **10,74**. Embora funcional como prova de conceito, o modelo *tiny-gpt2* apresentou limitações na qualidade semântica das frases em português.
- **Segurança:** O pipeline demonstrou eficácia na **anonimização de dados sensíveis** (CPFs e telefones) e na aplicação de regras determinísticas que impedem a IA de realizar diagnósticos definitivos.

9 Discussão e Governança

O protótipo enfatiza que a IA deve atuar como **apoio à decisão**, e não como substituta do profissional. A arquitetura em grafo garante transparência, permitindo auditar cada passo da decisão clínica. Em casos de **Alto Risco**, o sistema utiliza caminhos determinísticos (regras fixas), evitando que a "criatividade" do modelo de linguagem gere orientações inadequadas em situações críticas.

10 Conclusão

O trabalho demonstra a viabilidade de integrar **modelos ajustados, recuperação de documentos e orquestração de agentes** em um sistema único e transparente. Para evoluções futuras, sugere-se a substituição do motor de texto por modelos mais robustos (como LLaMA ou GPT-4 via API) e a integração com protocolos oficiais do Ministério da Saúde.

FIAP

